



**I302 - Aprendizaje Automático
y Aprendizaje Profundo**

**Trabajo Práctico 4:
Aprendizaje No Supervisado**

Sofia Amalia Yabo

9 de junio de 2026

Ingeniería en Inteligencia Artificial

Resumen

En este trabajo se analizó el dataset Fashion MNIST (25.000 imágenes de 28×28 píxeles en escala de grises) mediante técnicas de aprendizaje no supervisado. Para llevarlo a cabo, se implementaron desde cero algoritmos de reducción de dimensionalidad (PCA) y de clustering (K-Means y GMM), y se entrenó un Autoencoder determinístico (AE) con PyTorch. El PCA determinó que 135 componentes son suficientes para retener el 90 % de la varianza, espacio latente que se utilizó como representación compacta en los experimentos subsiguientes. La calidad de las reconstrucciones del AE resultó comparable a la de PCA. Para el clustering, se evaluaron valores de K en el rango [5, 15] combinando el método de ganancias decrecientes con el Silhouette score. Finalmente, se aplicó una implementación propia de t-SNE sobre el espacio latente del PCA para visualizar los clusters, observando que las clases con morfología visual distintiva quedan bien separadas, mientras que las prendas superiores que comparten una silueta similar presentan mayor mezcla entre sus respectivos clusters.

1. Introducción

El aprendizaje no supervisado es un conjunto de técnicas que busca descubrir la estructura interna en los datos sin usar etiquetas de antemano. A diferencia del aprendizaje supervisado, el algoritmo no recibe pares entrada-salida, sino que debe inferir patrones o agrupaciones compactas únicamente a partir de la distribución de los datos.

En este trabajo se aborda el dataset Fashion MNIST, cuya entrada consiste en imágenes de 28×28 píxeles en escala de grises (784 features por muestra) que representan diez categorías de prendas de vestir y accesorios: remeras, pantalones, pulóveres, vestidos, tapados, sandalias, camisas, zapatillas, bolsos y botas. El dataset contiene 25.000 muestras perfectamente balanceadas (2.500 por clase), lo cual elimina sesgos de representación a priori.

El objetivo del trabajo consiste de tres aspectos principales. Primero, reducir la dimensionalidad de los datos mediante PCA y un Autoencoder determinístico, comparando la calidad de las representaciones obtenidas. Segundo, aplicar algoritmos de clustering (K-Means y GMM) sobre el espacio latente comprimido para descubrir agrupaciones sin supervisión, y evaluar en qué medida estas agrupaciones recuperan las clases reales del dataset. Tercero, visualizar los clusters resultantes en dos dimensiones mediante t-SNE para analizar la estructura geométrica del espacio latente y la coherencia semántica de las particiones encontradas.

2. Métodos

2.1. Conjunto de datos y preprocesamiento

Se realizó un split estratificado para preservar la proporción de clases en cada subconjunto: 80 % de los datos se destinaron al entrenamiento (20.000 muestras) y el 20 % restante a la evaluación (5.000 muestras). La estratificación garantiza que cada partición mantiene la distribución original de clases.

Como único preprocesamiento, se aplicó estandarización (media cero, varianza unitaria) sobre los datos de entrenamiento, aprendiendo la media μ y el desvío estándar σ por feature exclusivamente sobre el conjunto de entrenamiento. Luego, la misma transformación fue aplicada al conjunto de test, evitando así cualquier filtración de información:

$$x'_i = \frac{x_i - \mu_i}{\sigma_i}$$

2.2. Reducción de dimensionalidad

2.2.1. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales es una técnica lineal de reducción de dimensionalidad que busca proyectar los datos sobre las direcciones de máxima varianza. Dado un conjunto de datos estandarizado $\mathbf{X} \in R^{n \times d}$, PCA computa la descomposición en autovectores de la matriz de covarianza $\mathbf{C} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$. Los autovectores asociados a los K mayores autovalores definen el subespacio de proyección, y los datos reducidos se obtienen como $\mathbf{Z} = \mathbf{X} \mathbf{W}_K$, donde $\mathbf{W}_K \in R^{d \times K}$ contiene los K autovectores seleccionados. La elección de K se realizó mediante el criterio de varianza explicada acumulada, seleccionando el mínimo número de componentes que alcanzara el 90 % de la varianza total. Este criterio arrojó $K = 135$ componentes.

2.2.2. Autoencoder Determinístico (AE)

Un autoencoder es una red neuronal que aprende una representación comprimida de los datos mediante dos subredes: un *encoder* $f_\phi : R^d \rightarrow R^K$ que mapea la entrada a un espacio latente de dimensión K , y un *decoder* $g_\theta : R^K \rightarrow R^d$ que reconstruye la entrada desde dicha representación. La red se entrena minimizando el error cuadrático medio (MSE) de reconstrucción:

$$\mathcal{L}(\phi, \theta) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - g_\theta(f_\phi(\mathbf{x}_i))\|^2$$

Para hacer la comparación con PCA justa, la dimensión latente se fijó en $K = 135$. La arquitectura implementada consiste en capas lineales con activaciones ReLU tanto en el encoder como en el decoder, con una activación sigmoide en la capa de salida para restringir la reconstrucción al rango de los datos normalizados. El modelo fue entrenado durante 50 épocas, con batches de tamaño 256 sobre los datos estandarizados.

2.3. Clustering

Para los experimentos de clustering se trabajó con una submuestra estratificada de 3.000 puntos en el espacio latente del PCA ($K = 135$ dimensiones).

2.3.1. K-Means

K-Means es un algoritmo iterativo que particiona n puntos en K clusters minimizando la inercia (suma de distancias cuadráticas intra-cluster):

$$\mathcal{L} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

El algoritmo alterna entre dos pasos: asignación de cada punto al centroide μ_k más cercano, y actualización de los centroides como la media de los puntos asignados a cada cluster. Se probaron valores de $K \in \{5, 6, \dots, 15\}$.

2.3.2. Mixture of Gaussians (GMM)

El modelo de mezcla de Gaussianas asume que los datos provienen de una combinación de K distribuciones normales, cada una parametrizada por su media μ_k , matriz de covarianza Σ_k y peso de mezcla π_k . Los parámetros se estiman mediante el algoritmo Expectation-Maximization (EM), que alterna entre el paso E (cómputo de responsabilidades $r_{ik} = P(z_k|\mathbf{x}_i)$) y el paso M (actualización de parámetros maximizando la log-verosimilitud esperada). Al igual que K-Means, se evaluaron valores de $K \in \{5, \dots, 15\}$.

2.3.3. Selección de K

Para seleccionar el número óptimo de clusters se emplearon dos criterios complementarios:

- **Ganancias decrecientes:** para K-Means se analiza la reducción marginal de inercia al incrementar K (método del codo); para GMM, la ganancia marginal en log-verosimilitud. El K óptimo corresponde al punto donde la ganancia adicional comienza a ser despreciable.
- **Silhouette score:** mide la cohesión intra-cluster y la separación inter-cluster para cada muestra. Para la muestra i , se define como $s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$, donde a_i es la distancia media a los puntos del mismo cluster y b_i la distancia media al cluster vecino más cercano. El score global es la media de s_i sobre todas las muestras; valores cercanos a 1 indican clusters bien definidos.

2.4. Visualización: t-SNE

Para visualizar los clusters resultantes en dos dimensiones se implementó el algoritmo *t-distributed Stochastic Neighbor Embedding* (t-SNE). t-SNE construye una distribución de probabilidad sobre pares de puntos en el espacio de alta dimensión que captura similitudes locales, y busca una representación de baja dimensión cuya distribución de probabilidades inducida (basada en la distribución t de Student) minimice la divergencia KL respecto a la distribución original. Se utilizó perplexidad = 30, tasa de aprendizaje = 200 y 500 iteraciones, aplicado sobre las 3.000 muestras en el espacio latente PCA de 135 dimensiones.

3. Resultados

3.1. Inspección del dataset

El análisis exploratorio confirmó que el dataset se encuentra perfectamente balanceado: cada una de las 10 clases contiene exactamente 2.500 muestras (ver Figura 1). Este balance es deseable porque evita sesgos de representación durante el entrenamiento y garantiza que las métricas de evaluación no estén distorsionadas por diferencias en la frecuencia de clase.




Figura 1: Distribución de clases en el dataset *Fashion MNIST*. Cada una de las 10 categorías de prendas contiene exactamente 2.500 muestras, confirmando el balance perfecto del conjunto de datos.

Al visualizar muestras agrupadas por clase (Figura 2), se observó que existe considerable variabilidad intra-clase (diferencias de color, textura, largo y diseño), y que ciertas clases presentan similitudes visuales entre sí, particularmente vestidos, tapados y pulóveres. Esta ambigüedad visual anticipó posibles dificultades para los modelos no supervisados en distinguir dichas categorías.




Figura 2: Muestras representativas de 5 clases del dataset (8 imágenes por clase).

3.2. Reducción de dimensionalidad

3.2.1. PCA

La Figura 3 muestra la varianza explicada acumulada en función del número de componentes principales. Se observa que la curva crece rápidamente en los primeros componentes y luego se aplanan progresivamente, patrón típico de datos de imágenes con estructura espacial redundante. El criterio del 90% de varianza acumulada determinó $K = 135$ componentes, lo que representa una reducción de la dimensionalidad de 784 a 135 features.




Figura 3: Varianza explicada acumulada en función del número de componentes principales.

La Figura 4 muestra una comparación entre imágenes originales y sus reconstrucciones mediante PCA ($K = 135$) y el Autoencoder ($K = 135$). Las reconstrucciones de PCA preservan la estructura global de cada prenda con cierta pérdida de detalle fino, lo cual es esperable dado que PCA descarta las componentes de menor varianza que típicamente codifican dichos detalles. Las reconstrucciones del AE presentan una calidad comparable, aunque con diferencias sutiles.




Figura 4: Comparación de 10 imágenes del conjunto de validación (fila superior: originales; fila media: reconstrucciones PCA; fila inferior: reconstrucciones del Autoencoder). Ambos métodos preservan la estructura global de la prenda.

3.3. Clustering

3.3.1. Selección del número de clusters

La Figura 5 presenta los criterios utilizados para determinar el K óptimo. Para K-Means, la curva de inercia decrece monótonamente sin un codo pronunciado, mientras que la ganancia marginal muestra una caída pronunciada hasta $K = 8$ y se va aplanando a partir de ese punto, sugiriendo que agregar clusters adicionales aporta reducciones de inercia cada vez menores. Para GMM, la ganancia marginal en log-verosimilitud presenta un comportamiento inestable a lo largo del rango evaluado, sin un punto de inflexión evidente, por lo que este criterio resultó poco concluyente.

El Silhouette score resultó el criterio más informativo: K-Means presenta valores consistentemente superiores a GMM para todo el rango $K \in [5, 15]$, lo que sugiere que la geometría de los clusters en el espacio latente del PCA es aproximadamente esférica y favorece las hipótesis de K-Means. Dentro de K-Means, el Silhouette alcanza valores similares entre $K = 6$ y $K = 10$. Dado que la ganancia marginal de inercia se aplanan precisamente a partir de $K = 8$, se tomó este criterio como desempate y se seleccionó $K = 8$ con K-Means como configuración óptima para el análisis posterior.




Figura 5: Análisis de selección del número de clusters $K \in [5, 15]$. **Superior izquierdo:** inercia de K-Means en función de K . **Superior derecho:** ganancia marginal de inercia (método del codo) para K-Means. **Inferior izquierdo:** ganancia marginal de log-verosimilitud para GMM. **Inferior derecho:** Silhouette score para K-Means (azul) y GMM (naranja). K-Means maximiza el Silhouette score en $K = 8$, valor seleccionado como óptimo.

3.3.2. Relación entre K óptimo y clases reales

El valor $K = 8$ obtenido es inferior al número real de clases del dataset (10). Esto es coherente con la estructura visual del problema: varias clases de prendas superiores (*T-shirt/top*, *Shirt*, *Pullover*, *Coat*, *Dress*) comparten morfología similar en el espacio de píxeles y, en consecuencia, en el espacio latente del PCA. Los métodos no supervisados, al no disponer de etiquetas, tienden a fusionar estas clases visualmente afines en un número menor de grupos que el existente realmente en los datos.

3.3.3. Visualización t-SNE y calidad de los clusters

La Figura 6 presenta la proyección t-SNE en 2D de las 3.000 muestras, coloreadas según el cluster asignado por K-Means con $K = 8$ (panel izquierdo) y según la clase real (panel derecho).




Figura 6: Proyección t-SNE de 3.000 muestras en el espacio latente del PCA ($K = 135$ dimensiones). **Izquierda:** coloreado por cluster asignado por K-Means ($K = 8$). **Derecha:** coloreado por clase real del dataset.

La comparación entre ambos paneles revela que los clusters con mayor cohesión y separación corresponden a clases con morfología visual distintiva: *Trouser* forma una región compacta y bien separada en la zona inferior derecha, mientras que *Ankle boot* y *Sneaker* ocupan regiones diferenciadas en el sector izquierdo del embedding. Estas clases presentan la mayor homogeneidad intra-cluster, con una clase dominante que explica una proporción elevada de las muestras de cada grupo.

Por el contrario, la región central-superior del embedding concentra las prendas superiores (*T-shirt/top*, *Pullover*, *Coat*, *Shirt*, *Dress*), formando un área de alta densidad con considerable mezcla entre clusters. En esta zona, K-Means establece fronteras geométricas que no respetan necesariamente las fronteras reales, dado que su hipótesis de clusters esféricos no captura adecuadamente la estructura superpuesta de estas clases en el espacio latente.

En conjunto, los resultados sugieren que la confusión residual observada en la zona de prendas superiores no es atribuible a una limitación del algoritmo de clustering en sí, sino a la proximidad intrínseca de dichas clases en el espacio de representación aprendido por PCA.